

Mini Curso 9: Classificação de uso e cobertura da terra utilizando o algoritmo Random Forest na plataforma Google Earth Engine.

Instrutores:

Camila Lauria Zenke da Cruz

Eduardo Lacerda

Isabela Rubatino

Novembro de 2020

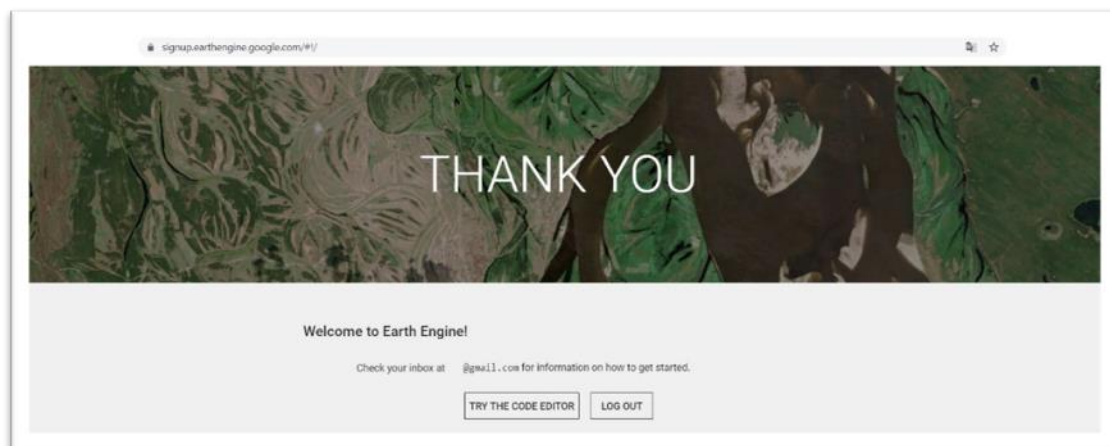
Passo 1: Criando e Acessando sua conta na Plataforma Google Earth Engine (GEE).

1.1. Para obter acesso ao Earth Engine, é importante que o usuário já tenha cadastro no Gmail.

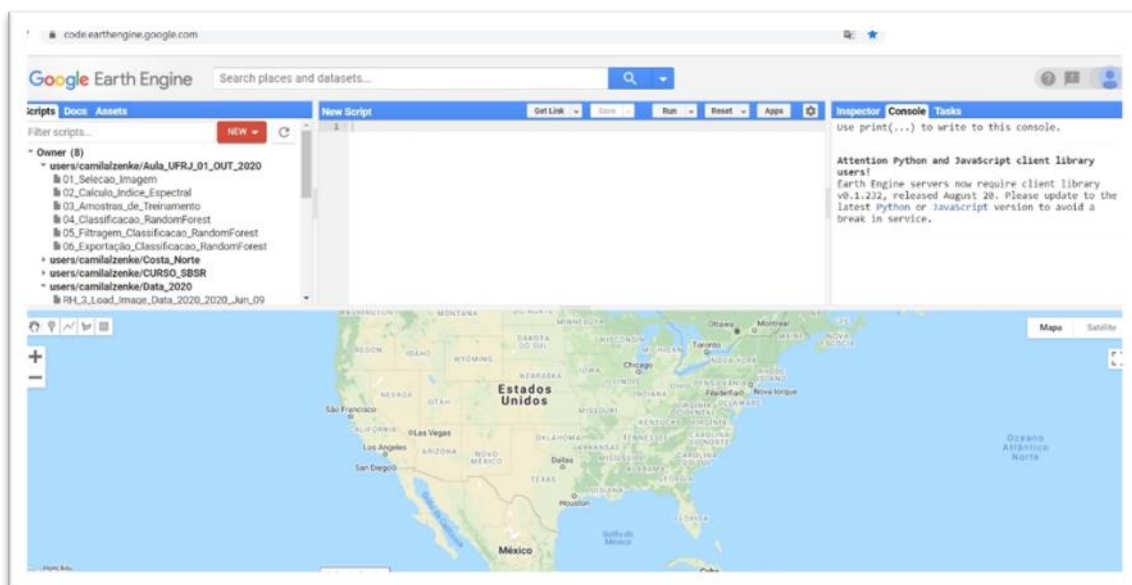
Você pode realizar o seu cadastro em: <https://www.google.com/intl/pt-BR/gmail/about/>.

1.2. Em seguida, preencha o formulário em: signup.earthengine.google.com. Você receberá um e-mail com o título: "Bem-vindo ao Google Earth Engine" com instruções para começar.

1.3. Nosso curso será realizado na interface **Code Editor** do GEE. Para visualizá-lo, acesse: signup.earthengine.google.com e informe o seu login e senha. Você será direcionado para a página abaixo.



1.4. Clique em **Try The Code Editor** e você será direcionado para o Code Editor.

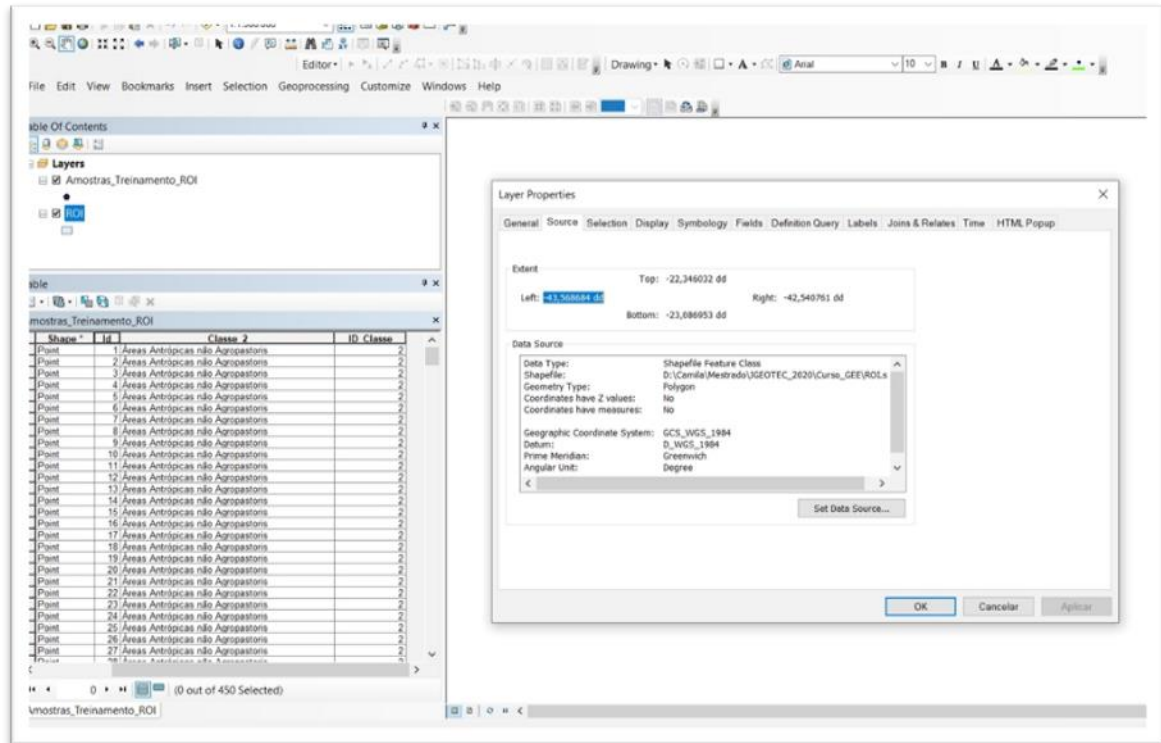


Dúvidas? Acesse: <https://earthengine.google.com/faq/>

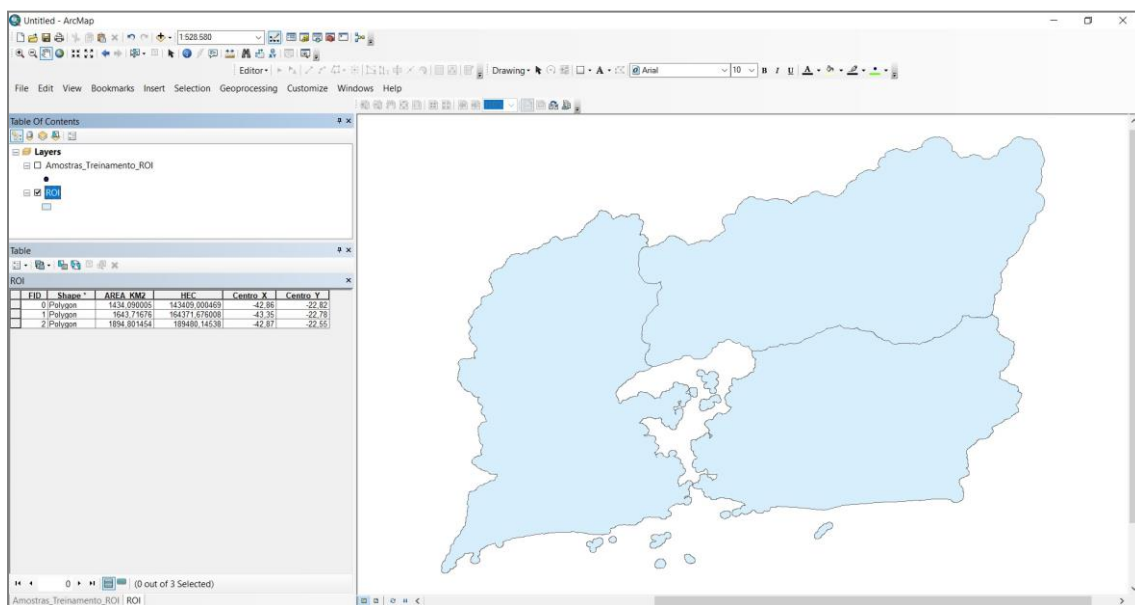
Passo 2: Upload da Área de Estudo (ROI) e Amostras de Treinamento.

2.1 Verificação dos Arquivos Recebidos

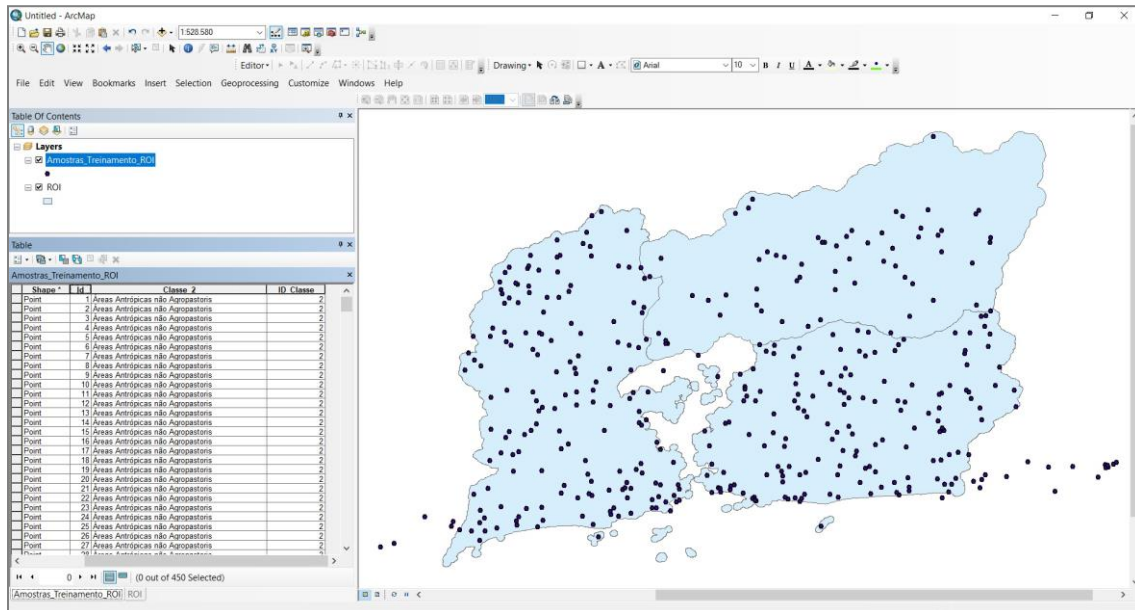
Em um SIG (Arcgis, Qgis, outros) abra os arquivos **ROI** e **Amostras de Treinamento**. Eles devem estar referenciados ao Sistema de Referência WGS 84.



Em relação aos atributos, os arquivos **ROI** e **Amostras de Treinamento** deverão apresentar as seguintes configurações:



Configuração do Arquivo **ROI**



Configuração do Arquivo **Amostras de Treinamento**, total de **450 pontos**, **7 classes** temáticas:

Áreas Antrópicas Agropastoris > ID_Classe 1

Áreas Antrópicas Não Agropastoris > ID_Classe 2

Cobertura Florestal > ID_Classe 3

Praia > ID_Classe 4

Área úmida > ID_Classe 5

Água > ID_Classe 6

Afloramento Rochoso > ID_Classe 7

2.2 Upload na Plataforma GEE dos Arquivos ROI e Amostras de Treinamento

2.2.1. Certifique-se de que ambos os arquivos estejam Agrupados em .ZIP

2.2.2. No Code Editor, acesse o campo **Assets > New > Shape Files**. Aparecerá a seguinte Janela:

Source files

SELECT

Please drag and drop or select files for this asset.
Allowed extensions: shp, zip, dbf, prj, shx, cpq, fix, qix, sbn or shp.xml.

Asset ID

users/camilalzenke/▼ Asset Name

Properties

Metadata properties about the asset which can be edited during asset upload and after ingestion. The "system:time_start" property is used as the primary date of the asset.

Add start time Add end time Add property

Advanced options

Character encoding

UTF-8 🔍 ?

Maximum error

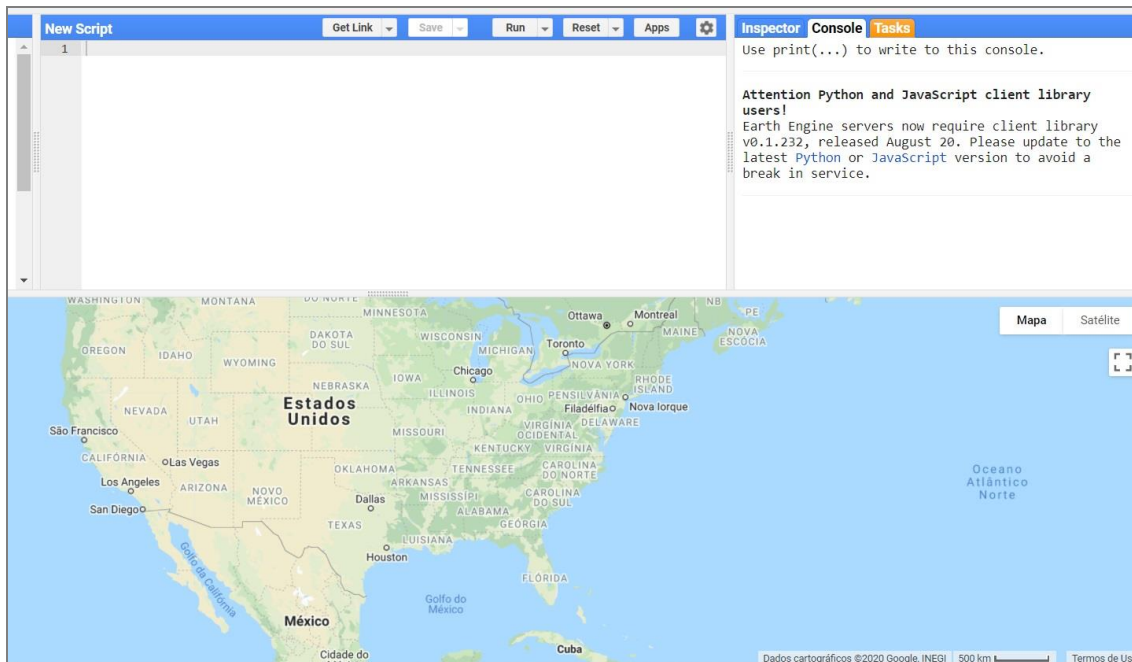
1.0 ?

☐ Split large geometries ?

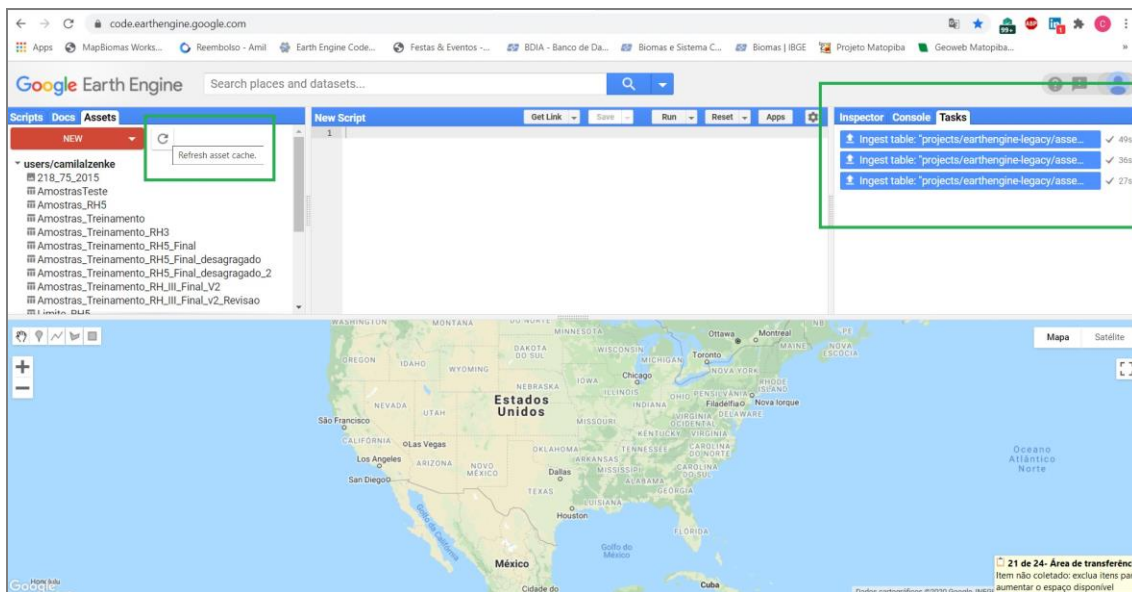
[Learn more](#) about how uploaded files are processed.

CANCEL UPLOAD

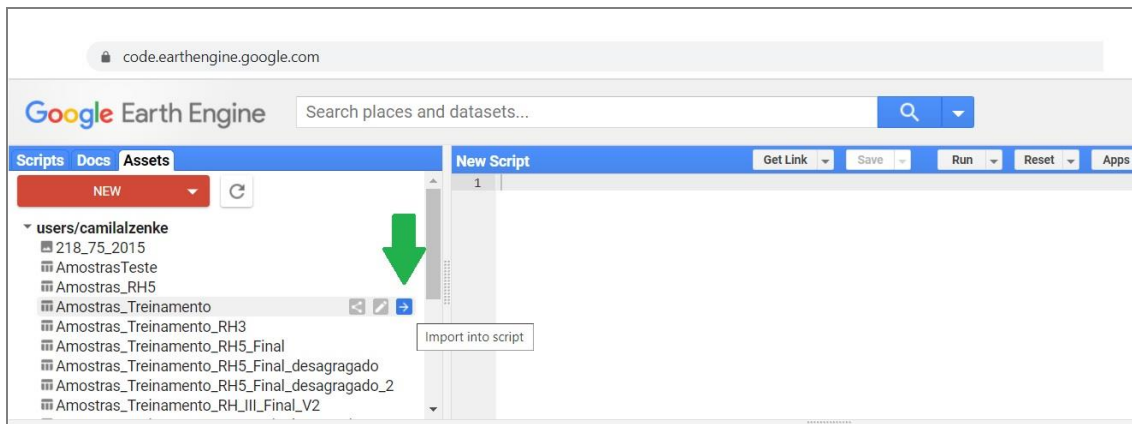
2.2.3. Para adicionar os arquivos, vá em **Select**, e selecione o Primeiro Arquivo (ROI ou Amostras de Treinamento). Em **Asset ID**, nomeie os arquivos (se necessário) como ROI e Amostras_Treinamento. Depois clique em **Upload**. O Campo **Tasks** piscará em **Amarelo**.



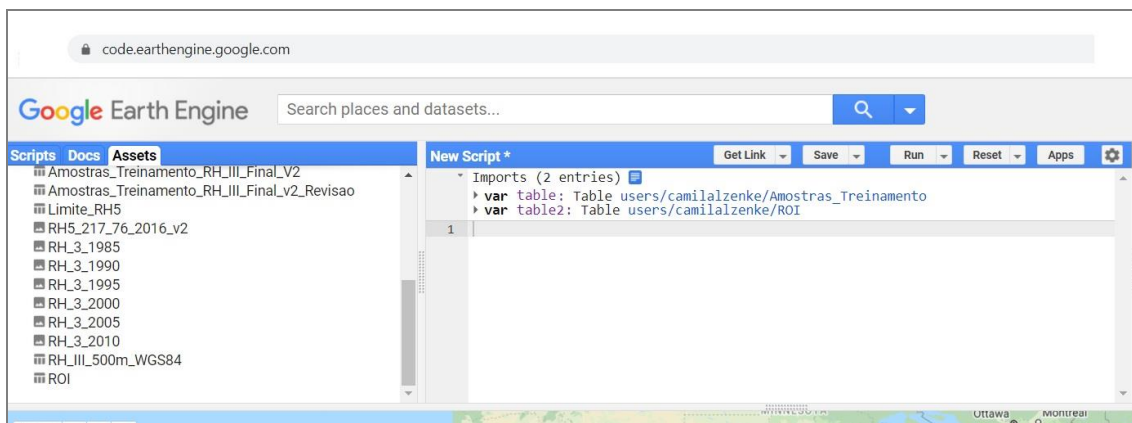
Você deve selecioná-lo e se necessário, clicar na opção **Ingest Table**. Em seguida, repita o passo para o **upload** do segundo arquivo. Após a conclusão do carregamento, os arquivos estarão na cor azul, no campo **Tasks**. No final, Volte ao Campo **Assets** e clique em **Refresh asset Cache**. Seus arquivos deverão estar disponíveis neste campo.



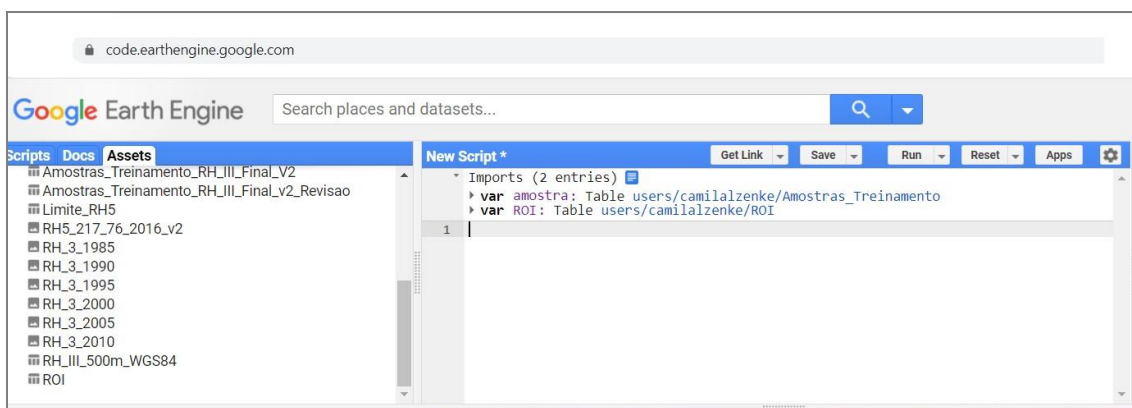
Em seguida, será necessário importar os arquivos **ROI** e **Amostras de Treinamento** para o **Code Editor**. Para isso, deve-se acessar o campo **Assets** > **posicionar o cursor do Mouse sobre o arquivo** > **clicar na seta (->) import into script**.



Eles serão automaticamente enviados ao Code Editor com os títulos **Table** e **Table2**.



Em Seguida, renomeie os arquivos apenas clicando em cima dos nomes **Table** e **Table2** para **amostra** e **ROI**:



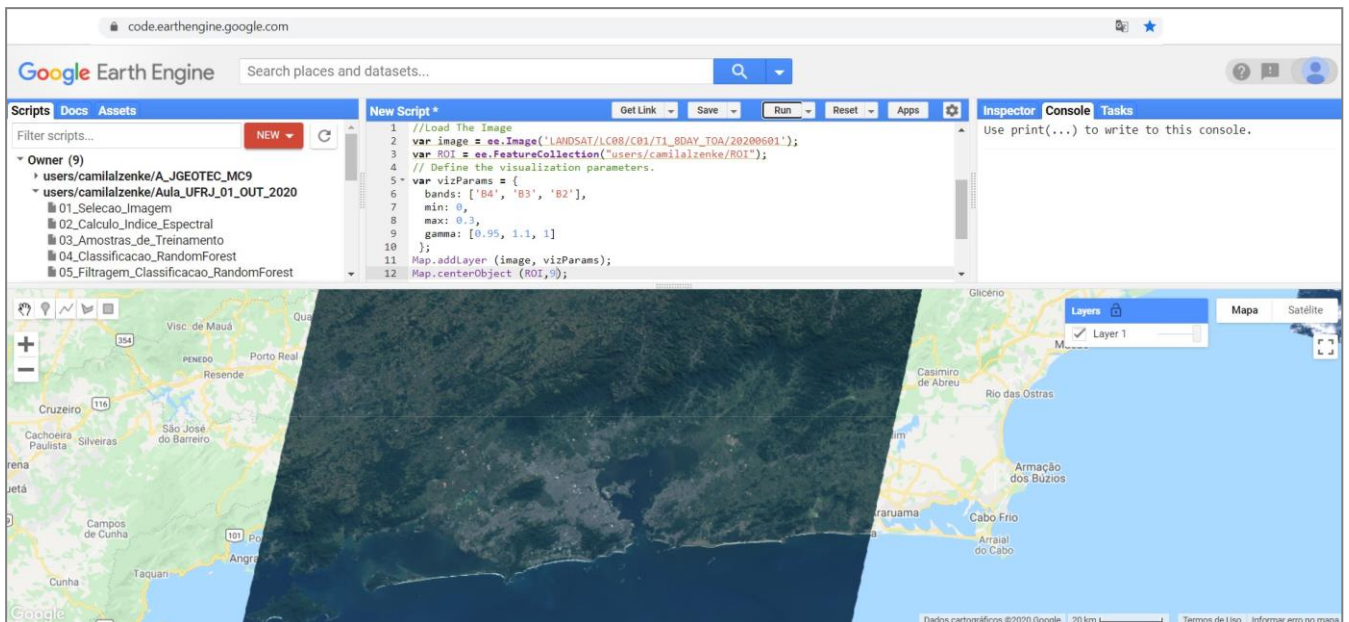
2.3 Seleção da Imagem e Criação de Composites LANDSAT-8

Neste passo, iremos selecionar a imagem Landsat-8 que iremos classificar. Para isso, iremos criar um Composite Landsat – 8 , de 8 dias, para garantir que tenhamos uma imagem com menor percentual de nuvens possível.

No Code editor, escreveremos o Código:

```
//Load The Image
var image = ee.Image('LANDSAT/LC08/C01/T1_8DAY_TOA/20200601');
var ROI = ee.FeatureCollection("users/camilalzenke/ROI");
// Define the visualization parameters.
var vizParams = {
  bands: ['B4', 'B3', 'B2'],
  min: 0,
  max: 0.3,
  gamma: [0.95, 1.1, 1]
};
Map.addLayer(image, vizParams);
Map.centerObject(ROI,9);
```

Após digitar o código, clique no botão **Run**.



2.4 Cálculo do Índice Espectral: NDVI

Após a seleção da Imagem, geraremos o NDVI do Composite Landsat-8 selecionado:

```
//Compute Normalized Difference Vegetation Index
// NDVI = (NIR - RED) / (NIR + RED), where
// RED is sur_refl_b03, 620-670nm // NIR is sur_refl_b04, 841-876nm

//Load The Image
var image = ee.Image('LANDSAT/LC08/C01/T1_8DAY_TOA/20200601');

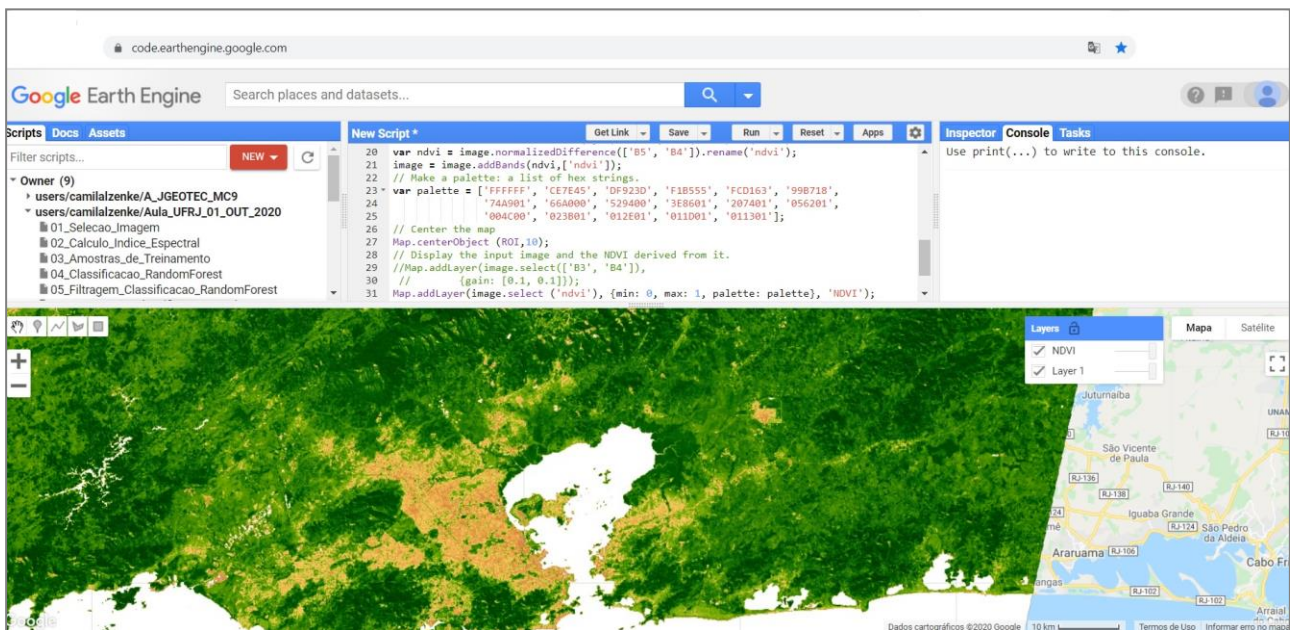
// Use the normalizedDifference(A, B) to compute (A - B) / (A + B)
var ndvi = image.normalizedDifference(['B5', 'B4']).rename('ndvi');
image = image.addBands(ndvi,['ndvi']);

// Make a palette: a list of hex strings.
var palette = ['FFFFFF', 'CE7E45', 'DF923D', 'F1B555', 'FCD163', '99B718',
              '74A901', '66A000', '529400', '3E8601', '207401', '056201',
              '004C00', '023B01', '012E01', '011D01', '011301'];

// Center the map
Map.centerObject (ROI,10);

// Display the input image and the NDVI derived from it.
//Map.addLayer(image.select(['B3', 'B4']),
//    {gain: [0.1, 0.1]});

Map.addLayer(image.select ('ndvi'), {min: 0, max: 1, palette: palette}, 'NDVI');
```



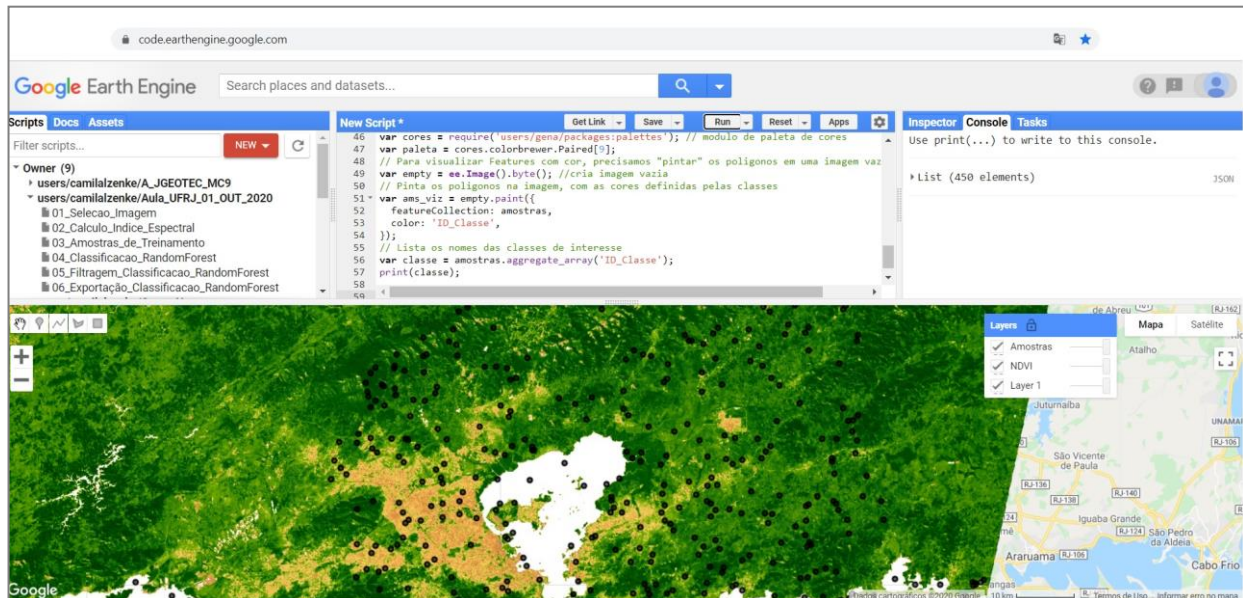
OBS: A Paleta de Cores Hexadecimal pode ser encontrada em Diversos sites, como o <https://celke.com.br/artigo/tabela-de-cores-html-nome-hexadecimal-rgb>. Basta Digitar Paleta de Cores Hexadecimal no seu buscador.

2.5. Carregando Amostras de Treinamento

Nesta etapa, iremos informar as amostras de treinamento que serão usadas para classificação e validação do RandomForest.

```
// Carregando as amostras de treinamento
var amostras = ee.FeatureCollection("users/camilalzenke/Amostras_Treinamento");
//Aqui estou carregando as amostras com os parâmetros de cor escolhido para cada classe.
//É importante lembrar que, o Mapadlayer para ser carregado precisa ter a estrutura:
Map.addlayer (dado, {parametros de visualizacao}, 'nome').

var paleta = ['FFFFFF', '98FB98', 'FFAA88', '227B22', 'FF0000', 'F000F0', '007FFF', '000000'];
var empty = ee.Image().byte(); //cria imagem vazia
var ams_viz = empty.paint({
  featureCollection: amostras,
  color: 'ID_Classe',
});
// Visualiza os polígonos usando a paleta criada
Map.addLayer(amostras, {palette:paleta, min:1, max:9}, 'Amostras');
// Criando rampa de cores para os dados de treinamento
var cores = require('users/gena/packages:palettes'); // modulo de paleta de cores
var paleta = cores.colorbrewer.Paired[9];
// Para visualizar Features com cor, precisamos "pintar" os poligonos em uma imagem vazia
var empty = ee.Image().byte(); //cria imagem vazia
// Pinta os poligonos na imagem, com as cores definidas pelas classes
var ams_viz = empty.paint({
  featureCollection: amostras,
  color: 'ID_Classe',
});
// Lista os nomes das classes de interesse
var classe = amostras.aggregate_array('ID_Classe');
print(classe);
```



2.6. Classificação com o Algoritmo *SmileRandomForest*

Aqui iremos classificar nossa Imagem Utilizando o algoritmo RandomForest. Para isso:

- Apontamos ao algoritmo quais bandas espectrais do Composite desejamos utilizar;
- Indicamos ao algoritmo que ele use o NDVI e as amostras de treinamento;
- Definimos o tamanho do Pixel de Saída (30 metros);
- Indicamos para o algoritmo que, das 450 amostras de treinamento fornecidas, 70 % serão selecionadas para o treinamento do classificador e 30% para a validação do classificador;
- Aplicamos o classificador aos parâmetros informados e as amostras de treinamento (70%);
- Calculamos a Matriz de Erro e Acurácia do classificador a partir das amostras de validação (30%). Contudo, é importante destacar que esta validação não reflete a validação final da imagem classificada, e sim à performance do algoritmo referente ao conjunto de treinamento. É necessário, em etapas posteriores, que se realize outras análises estatísticas para identificar a acurácia da classificação;
- Definimos o nº de Árvores de Decisão;
- Após o treinamento, o classificador é aplicado para toda a imagem;
- A imagem classificada é colorida de acordo com os valores Hexadecimais ou Paleta de Cores definidos.

Código:

```
// We define here the bands that contain spectral responses
var bandas = ['B1','B2', 'B3', 'B4', 'B5', 'B6', 'ndvi'];

// We extract the pixel values from the image to train the algorithms
var treinamento = image.sampleRegions({
  collection: amostras,
  properties: ['ID_Classe'],
  scale: 30
});

// creates a column of random values between 0 and 1
var aleatorio = treinamento.randomColumn('random');

// defines the cutoff point: 70% for training and 30% for testing
var split = 0.7;

// Separates who is above or below the cutoff point
var treino = aleatorio.filter(ee.Filter.lt('random', split));
var teste = aleatorio.filter(ee.Filter.gte('random', split));

var classificador = ee.Classifier.smileRandomForest ({numberOfTrees: 400}).train({
  features: treino,
  classProperty: 'ID_Classe',
  inputProperties:bandas
});

// We apply the classifier to the test data
var class_teste = teste.classify(classificador);

// We calculate the error and accuracy matrix
var confmat = class_teste.errorMatrix('ID_Classe','classification');
print('Matriz de Erro - RF1', confmat);
print('Acuracia - RF1', confmat.accuracy());

// We apply the classifier to the entire image
var classe = image.classify(classificador);

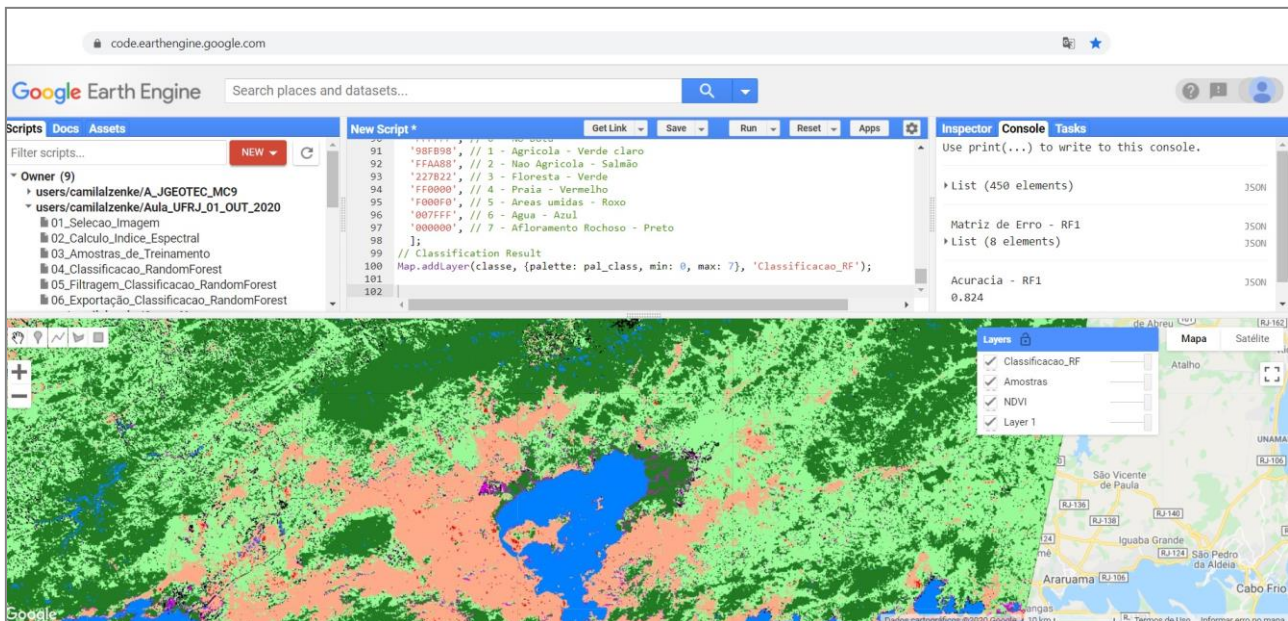
// Color palette for classes - RGB Hexadecimal:
// 'FFFFFF', '98FB98', 'FFAA88', '227B22', 'FF0000', '500080', '007FFF', '000000
```



```
var pal_class = [
    'FFFFFF', // 0 - No Data
    '98FB98', // 1 - Agricola - Verde claro
    'FFAA88', // 2 - Nao Agricola - Salmão
    '227B22', // 3 - Floresta - Verde
    'FF0000', // 4 - Praia - Vermelho
    'F000F0', // 5 - Areas umidas - Roxo
    '007FFF', // 6 - Agua - Azul
    '000000', // 7 - Afloramento Rochoso - Preto
];

// Classification Result

Map.addLayer(classe, {palette: pal_class, min: 0, max: 7}, 'Classificacao_RF');
```



2.7. Aplicação do Filtro Espacial

As Classificações Pixel a Pixel tendem a apresentar em seus resultados, o efeito sal e pimenta, com a presença de muitos ruídos. Para minimizá-los, é importante a aplicação de filtros espaciais.

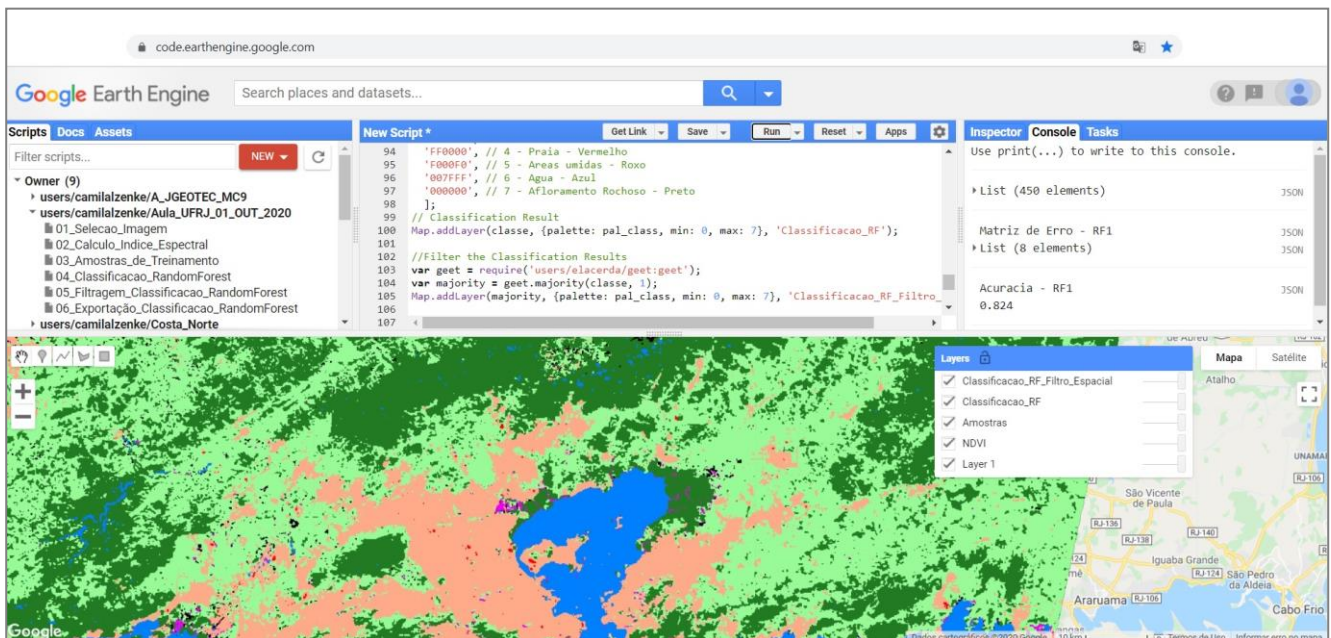
Aqui usaremos o filtro de moda Majority, disponibilizado gratuitamente pela plataforma GitHub¹. Neste filtro, o parâmetro Radius está relacionado com a construção da máscara através dos vizinhos mais próximos. Quanto maior for esse valor, maior será a generalização da filtragem. Nesta classificação, definiu-se o valor 1, o que significa que a seleção da máscara tem o limite de até um pixel de distância do pixel central, formando uma matriz de 3 x 3. É importante destacar que este é o valor mais conservador, resultando na menor generalização possível do resultado.

```
//Filter the Classification Results
```

```
var geet = require('users/elacerda/geet:geet');
```

```
var majority = geet.majority(classe, 1);
```

```
Map.addLayer(majority, {palette: pal_class, min: 0, max: 7}, 'Classificacao_RF_Filtro_Espacial');
```



¹ Disponível em: <https://github.com/sacridini/GEET#majority> (Acesso em 14/09/2020).

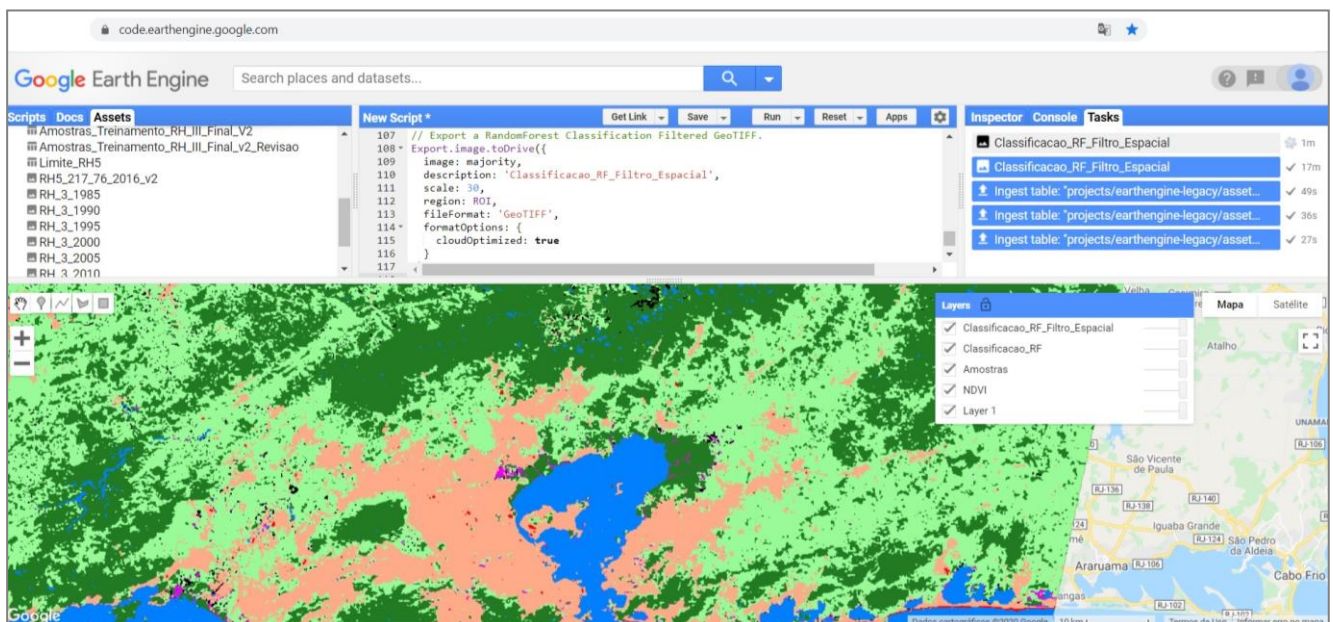
2.8. Exportando a Imagem Classificada

Neste Passo, vamos exportar, em GeoTIFF, para o nosso Drive, o resultado final da classificação. É importante verificar se há espaço de armazenamento disponível para isso.

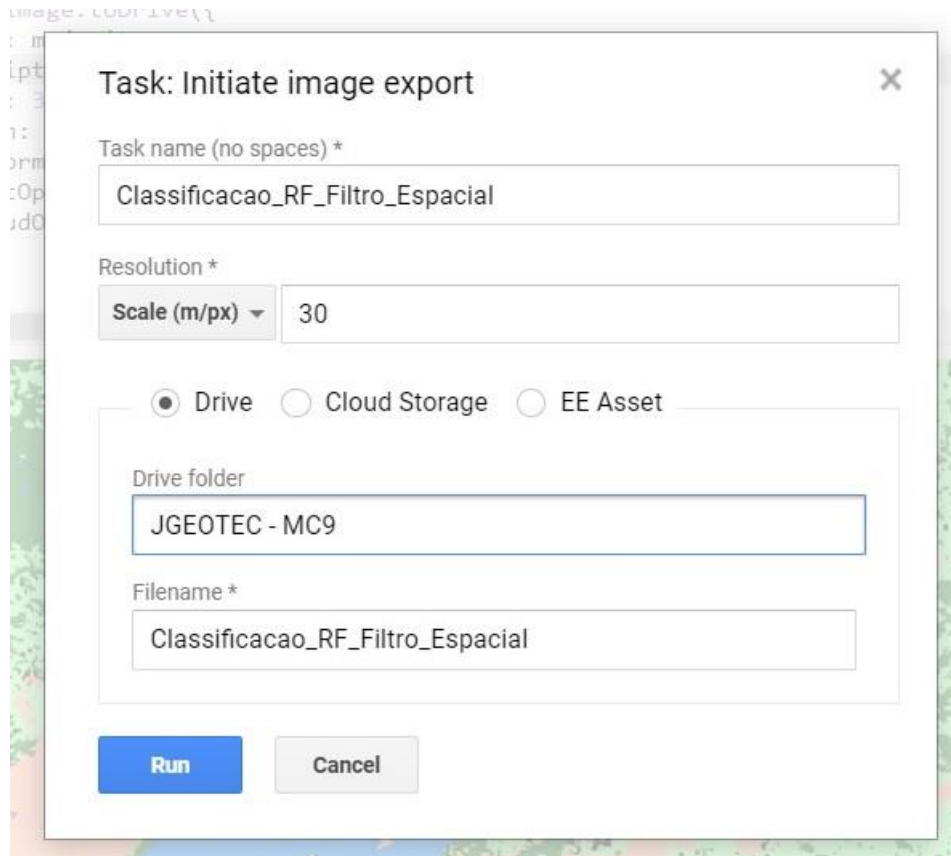
// Export a RandomForest Classification Filtered GeoTIFF.

```
Export.image.toDrive({
  image: majority,
  description: 'Classificacao_RF_Filtro_Espacial',
  scale: 30,
  region: ROI,
  fileFormat: 'GeoTIFF',
  formatOptions: {
    cloudOptimized: true
  }
});
```

Feito isso, a Imagem será adicionada ao campo **Tasks**, que novamente estará piscando em Amarelo. Clicar em **Run**, ao lado da Imagem recém adicionada.



Em seguida, irá abrir uma caixa para definir os parâmetros da exportação. Nela, no campo scale, você deve adicionar o valor 30, referente ao tamanho do pixel. E no campo Drive Folder, Indicar a pasta do seu drive para que a imagem seja salva. Depois, clicar **Run**.



Task: Initiate image export

Task name (no spaces) *

Classificacao_RF_Filtro_Espacial

Resolution *

Scale (m/px) ▾ 30

☒ Drive ☐ Cloud Storage ☐ EE Asset

Drive folder

JGEOTEC - MC9

Filename *

Classificacao_RF_Filtro_Espacial

Run Cancel

E Assim, finalizamos o curso! Parabéns!